スケーリング則の直感

参考資料 — 大きくすると、なぜ強くなるのか

rkskmt

この資料について

- 自作GPTは **約82万パラメータ**。ChatGPT までの距離の回では、GPT-3 がその約21万倍だと見た
- 残った問い：**部品を増やすだけで、本当に予測は上手くなるのか？**
- 同じ『吾輩は猫である』・同じGPT・同じ訓練歩数で、**幅だけ** を変えた5台を競わせる

クイズ：幅だけ広げると？

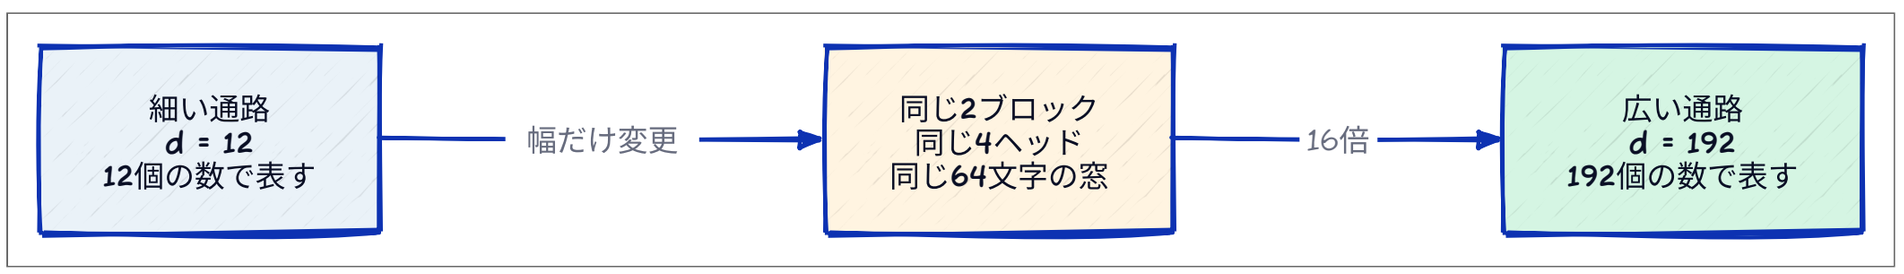
データも訓練歩数も同じまま、モデルの幅を16倍にする。初見の文章を当てる val loss はどうなると思う？

予想	起きそうなこと
A	小さい方が有利 — 大きいモデルは学びきれない
B	大きい方が有利 — 複雑な規則を持てる
C	途中までは改善するが、大きすぎると逆転する

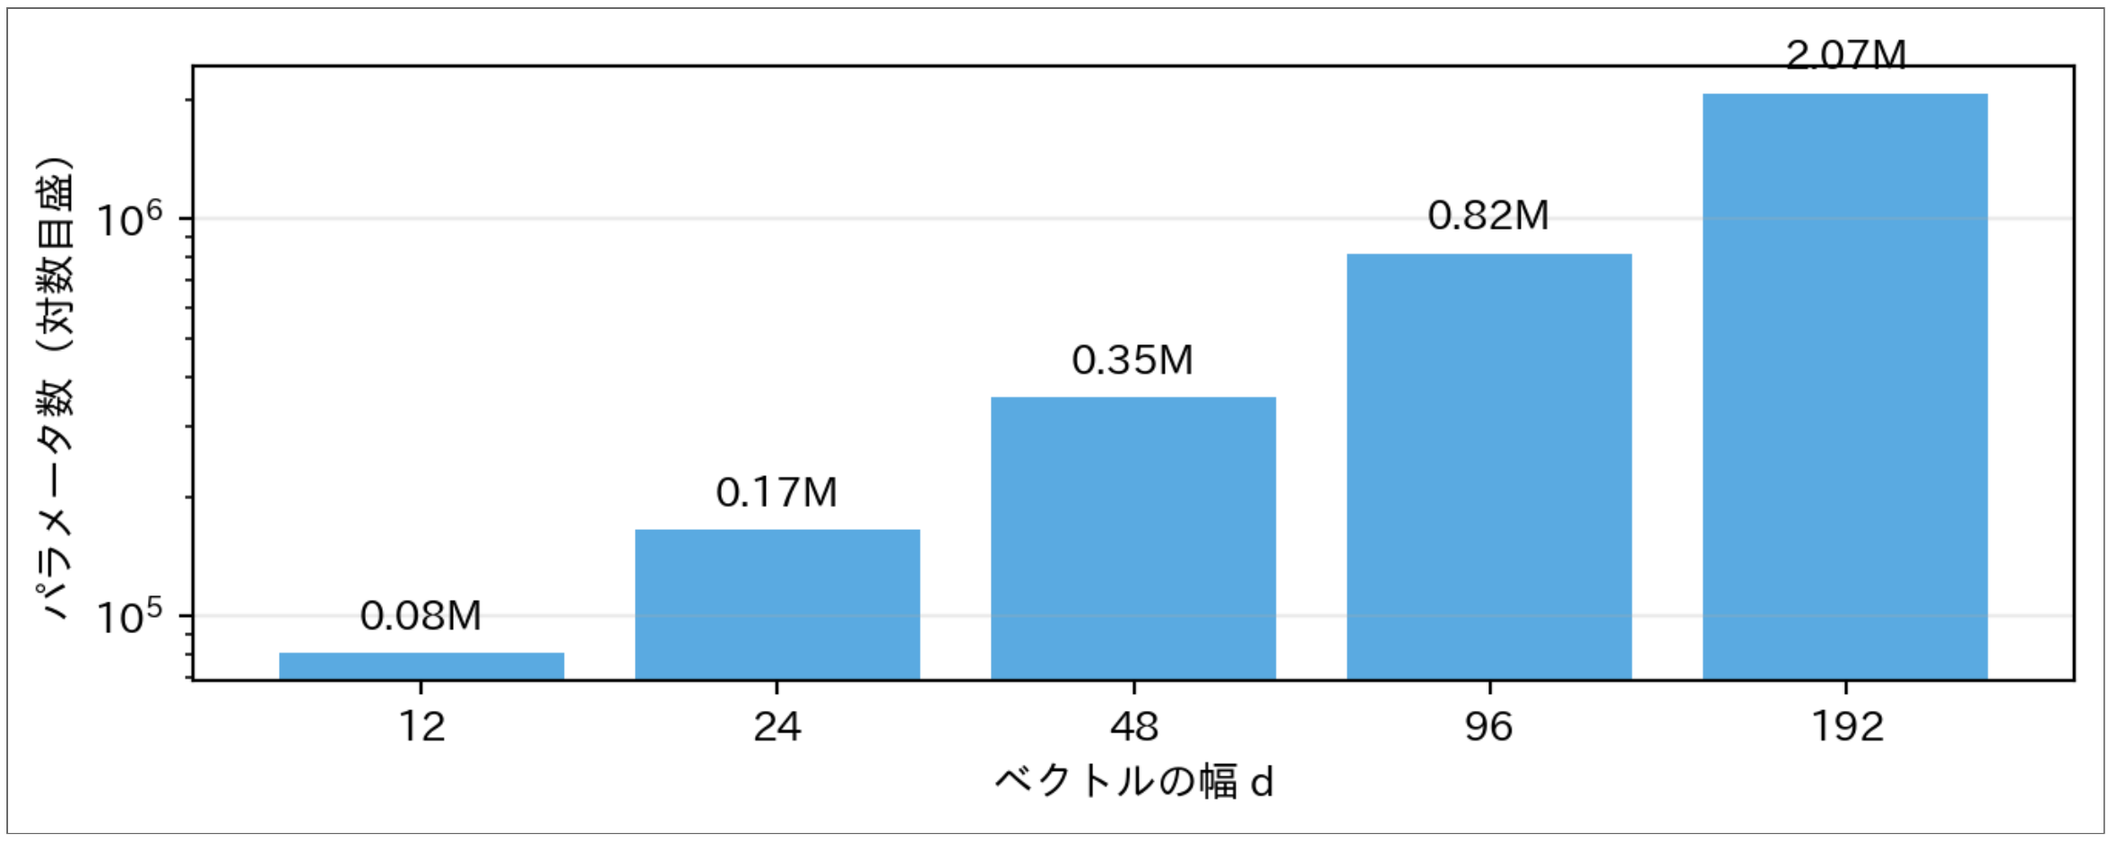
> **重要**
>
> 先に1つ選べ。答えは **実測した5点** で決める。

「大きくする」＝ ベクトルの幅を広げる

- 自作GPTの各文字は、幅 d のベクトルで旅をする — コードでは **`n_embd=d`**
- 幅が広いほど、1文字について **同時に持てる手がかり** を増やせる
- 行列は「幅 × 幅」のマスを持つため、幅を広げると部品は急に増える
- 層数・ヘッド数・窓の長さは固定し、今回はこの幅だけを変える



幅16倍、部品は約26倍



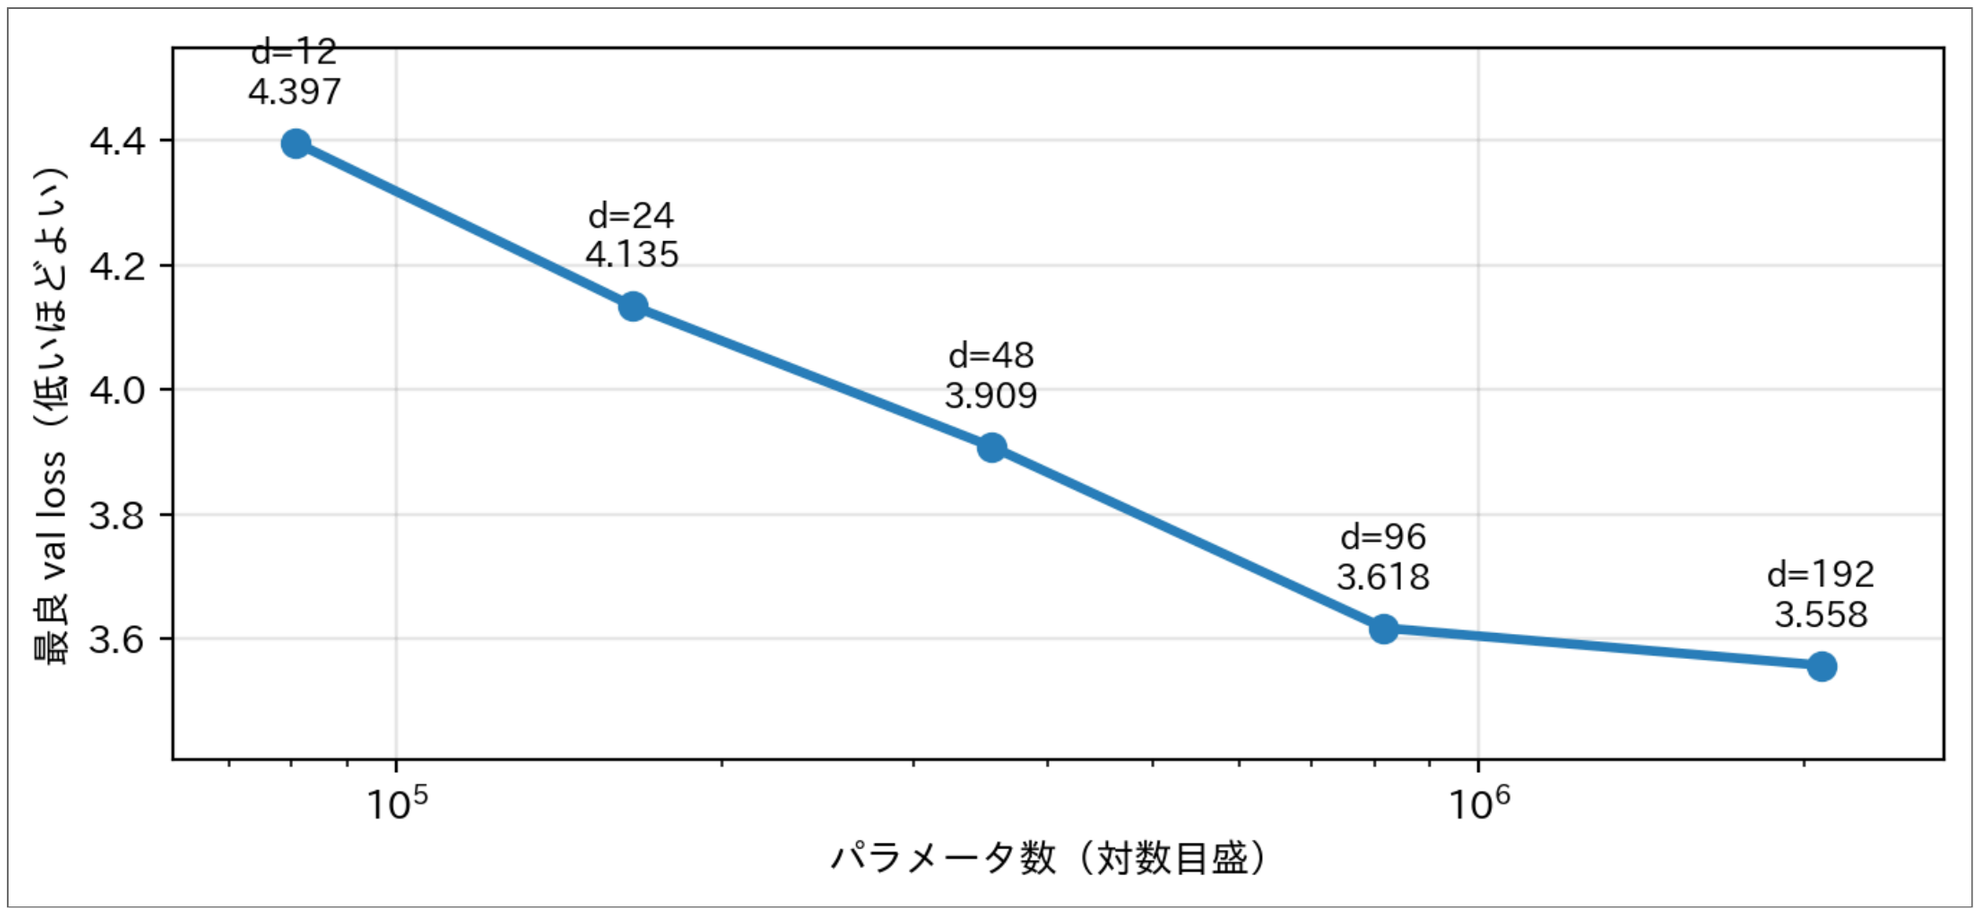
- d: 12 → 192 は **16倍** ／ パラメータ: 80,613 → 2,073,573 は **約25.7倍**

公平に競わせる

固定するもの	**5台すべて同じ**
データ	『吾輩は猫である』321,139字、先頭90%で訓練・末尾10%で検証
GPTの骨格	2ブロック・4ヘッド・64文字の窓
学習	batch 32・AdamW・学習率0.001・2,000歩・seed 42
採点	500歩ごとの val loss、その中の**最小値**

- 変えるのは **`n_embd = 12, 24, 48, 96, 192`** だけ
- **実験コード** ／ **実測CSV**

結果：大きいほど、底が下がった



- クイズの答えは、**「最良点」で比べれば B**

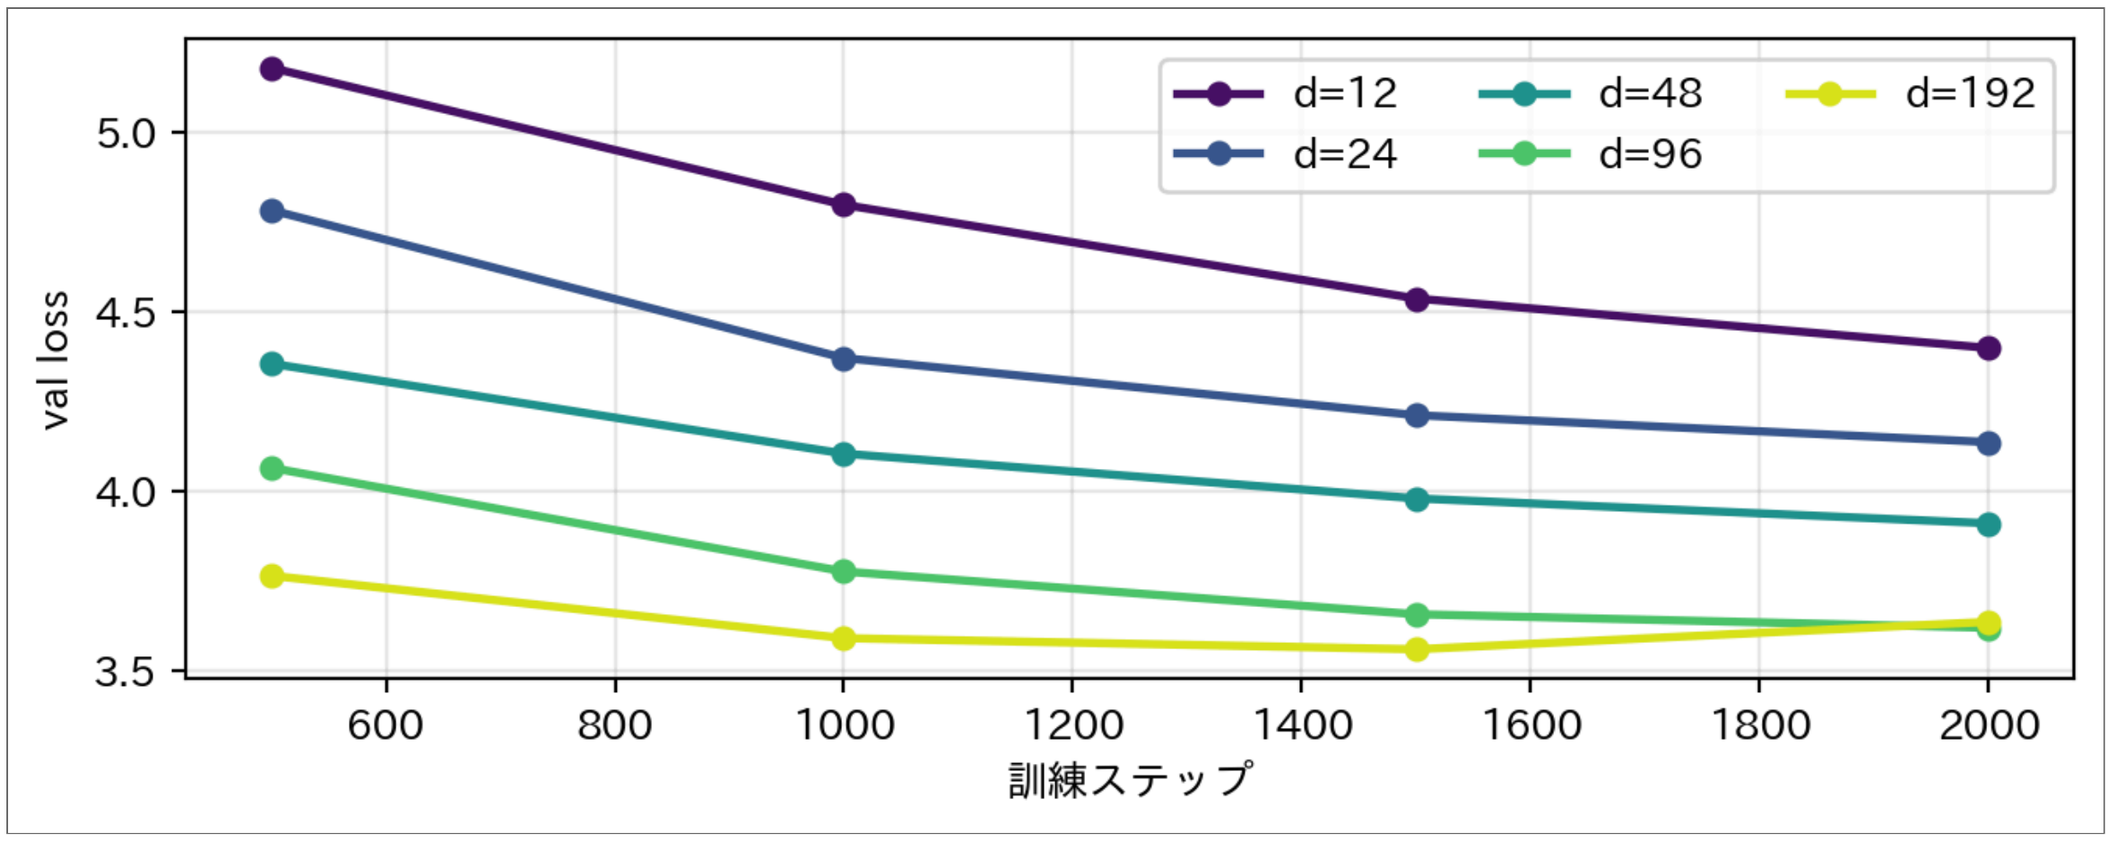
耳でも比べる

同じ「吾輩は」から、同じ温度・同じシードで80文字生成した実物：

幅	生成の冒頭
12	吾輩はある。「も、これ事だらうものだだないから、おっていい。…
96	吾輩はただ一人も多少なものだろう。それだけはこの時はこっちであるからも、…
192	吾輩は吾輩を知らぬにこの事だと同意した。その後学肉はこれから四畳を重んで…

- どれも意味は怪しい。それでも幅12の**助詞の崩れ**から、幅96・192では**長い文の型**へ進んだ
- loss の差は、文章の「音」にも現れる — **5台の全文**

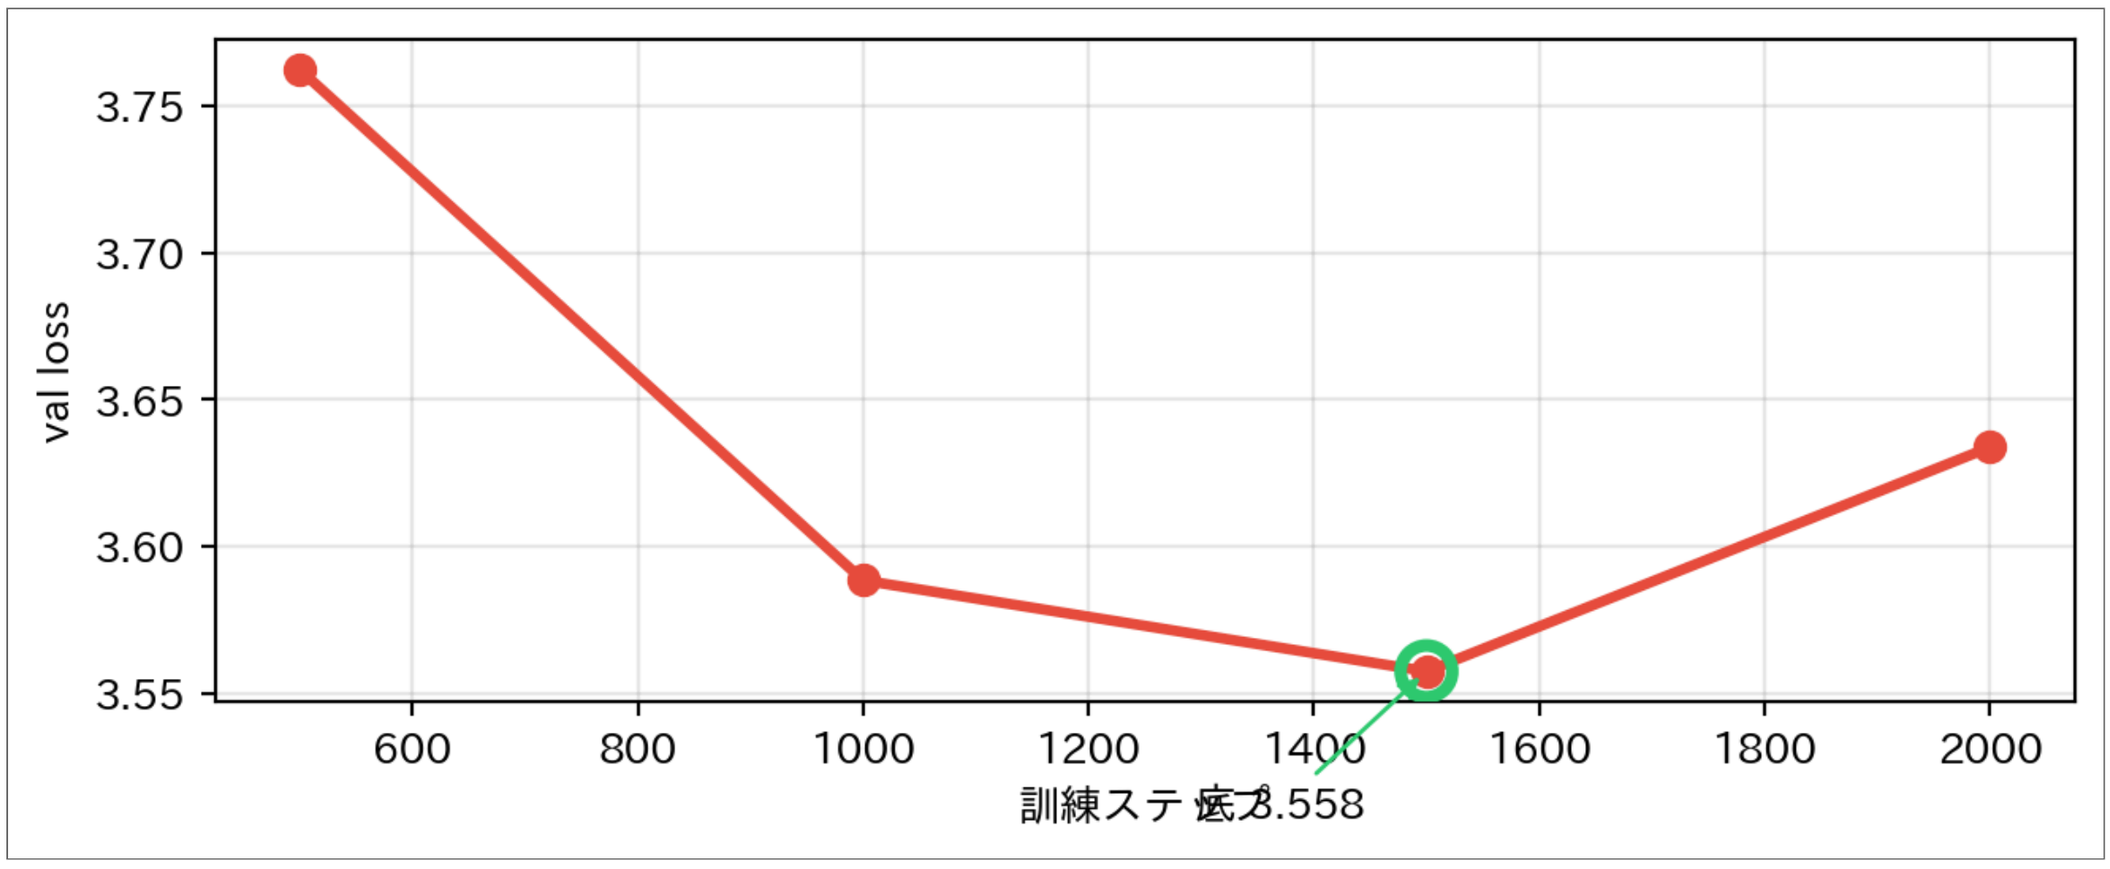
大きいモデルは、早く下がる



- わずか500歩で、幅192は **3.762**。幅12が2,000歩かけた **4.397** をすでに追い越す

9

ただし最大モデルだけ、Uターン



- 幅192は1,500歩で **3.558**、2,000歩では **3.634** に悪化。一方、train loss は2,000歩まで下がり続けた

10

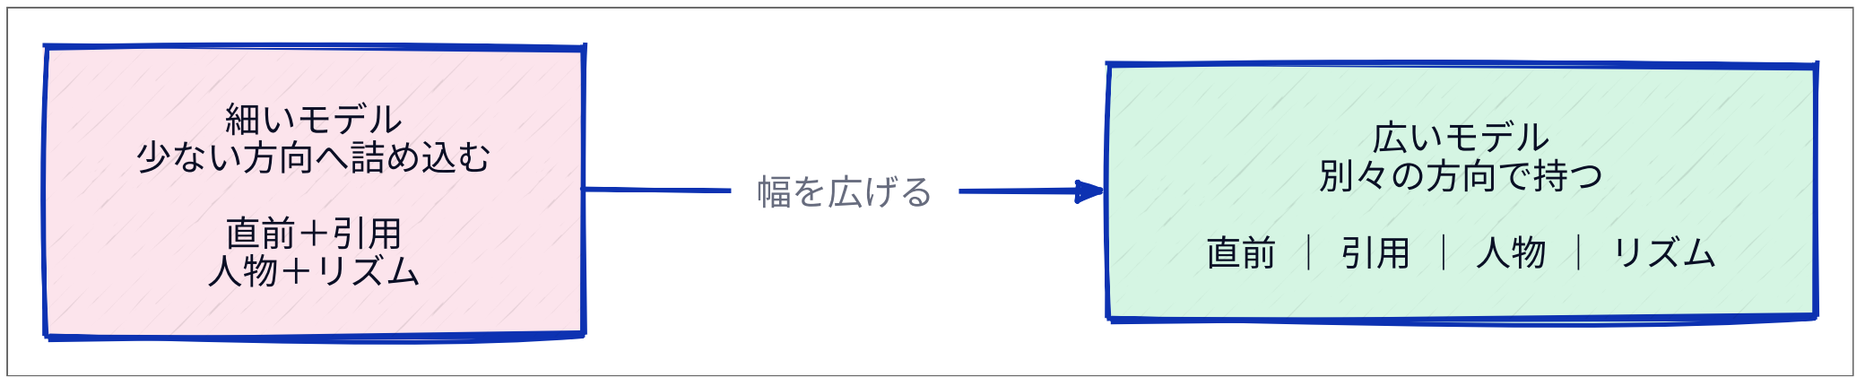
同じ2,000歩でも、公平とは限らない

- 容量が大きいほど、同じ1冊の細部まで覚えやすい — **早期終了**が早く必要になる
- 2,000歩の **最後だけ** で順位を決めると、幅96が幅192に勝つ。クイズの C も半分正しかった
- 各モデルの **best val** を比べれば、幅192が優勝 — 保存したチェックポイントから底を選ぶ

11

幅が増えると、何が増える？

- 細いモデルは、限られたベクトルに「直前の文字」「引用の中」「登場人物」などを押し込む
- 幅を広げると、より多くの手がかりを**別々の方向**として持てる
- 幅×幅の行列も広がり、手がかり同士の組み合わせを作る「つまみ」が増える



本物の「スケーリング則」

- 多数のモデルを測ると、loss は**モデル規模 N・データ量 D・計算量 C** に対して、なめらかな**べき乗則**（power law）を示す

$$L(N) \approx L_\infty + AN^{-\alpha} \qquad (\alpha > 0)$$

- N を増やすほど loss は下がる。ただし右へ行くほど改善幅は小さくなる
- この経験則が**スケーリング則**（scaling law） — 大型化する前に、必要な資源と期待できるlossを予測する地図
- 原論文：**Scaling Laws for Neural Language Models**（Kaplanほか、2020）

この5点は「法則のミニチュア」

- 今回固定したもの：データ量 D と訓練歩数。変えたもの：モデル規模 N だけ
- 8万〜207万パラメータの5点でも、対数目盛の横軸に対して**おおむね滑らかな右下がり**が現れた
- ただし5点の小実験から、実物LLMにも通用する指数 α は決められない
- 本物の研究は桁の違う多数のモデル・データ量・計算量を測る — **方向を体験したのであって、万能な式を証明したのではない**

大きい脳には、読む本も増やす

- 今回の最大モデルは、同じ『猫』1冊を早く覚えすぎて過学習した
- モデルだけ大きくしてデータを据え置くと、容量を使い切れない
- **Chinchilla** の実験は、限られた計算量を使うなら、モデル規模と訓練トークン数を**一緒に増やす**のがよいと示した
- 原論文：**Training Compute-Optimal Large Language Models**（Hoffmannほか、2022）

> ⓘ **ノート**
>
> 「一番大きいモデル」ではなく、**モデル・データ・計算の釣り合いがよいモデル**が強い。

大きさの請求書

幅	パラメータ	重みだけの容量（float32）
12	80,613	0.32 MB
96	817,125	3.27 MB
192	2,073,573	8.29 MB

- 訓練中は重みだけでなく、勾配・AdamWの状態・途中の活性も持つため、必要メモリはさらに増える
- 推論でも、モデルが大きいほど保存容量・計算・電力・待ち時間が増える
- scaling law は「大きくすれば無料で勝てる法則」ではなく、**追加コストを払ったときの改善を予測する法則**

読み解きクイズ

学習曲線CSV と成績表を見て答えよ。

1. 500歩時点で最も val loss が低い幅
2. 全測定点で最も低い val loss と、その幅・歩数
3. 2,000歩の最終値だけで比べた優勝モデル
4. 2と3の答えが違う理由

答え合わせ

1. 500歩：**幅192、3.762**
2. 全体の底：**幅192、1,500歩、3.558**
3. 最終値：**幅96、3.618**（幅192は3.634）
4. 幅192は学習が速く、2,000歩までに**過学習**へ入ったため

> **重要**
>
> モデルの比較では「同じ最終歩」だけでなく、各モデルの**最良 val**を比べる。チェックポイントを保存する理由もここにある。

まとめ

- 幅を16倍にするとパラメータは約26倍になり、最良 val loss は **4.397 → 3.558** に改善した
- 大きいモデルは**より低い地点へ、より速く**到達した — 複雑な手がかりを持つ容量が増える
- ただし最大モデルは同じ1冊を早く覚えすぎた — **早期終了と十分なデータ**が必要
- スケーリング則は、モデル N・データ D・計算 C を増やしたときの改善を予測する経験則
- 「大きければ正義」ではない。**3つの資源の釣り合い**まで含めて設計する